

15주차: Interpolating between Images with Diffusion Models

0. Abstract

이미지 생성, 편집에서 2개의 인풋 이미지를 보간하는 작업 중 feature missing 문제점이 있음.

이 논문에서는 잠재 확산 모델을 이용한 zero-shot interpolation을 제안함.

1. Introduction

이미지 편집은 CV, 생성형 모델에서 중요 주제였음. 생성 모델이 발전하며 실제 이미지 편집에 복잡한 기술들이 발전했고 최근에 denoising diffusion model이 나왔지만 실제 이미지 사이에 고품질의 interpolation 방식은 나오지 않음.

현재 이미지 보간 기술은 제한된 문맥에서만 작동. GAN의 잠재 공간 특성만 사용해 이미지 생성됨. 비디오 보간 기법은 스타일이 다른 이미지 사이에서 부드럽게 이어지지 않음.

이 논문에서는 이미지 사이의 고품질 보간 이미지 생성을 위해 pre-trained latent diffusion 모델을 이용함. pose estimation, CLIP scoring을 기준으로 보간.

2. Related Work

Image editing with latent diffusion models

Diffusion Models과 **Latent Diffusion Models**의 강력한 이미지 생성 및 편집 능력을 강조.

- **강점:** 텍스트 기반 사실적 이미지 생성, 다양한 조건(텍스트·포즈 등) 지원, 데이터 외 분포에서도 일반화 가능.
- **GAN과 비교:** GAN은 스타일·콘텐츠 분리에 강하지만, 실제 이미지 재구성(GAN Inversion)과 조건부 입력 처리에서 Diffusion Models보다 약점이 있음.
- **Latent Diffusion Models:** 생성 이미지 보간에서 우수하며, 이번 연구는 최초로 실제 이미지 보간을 Latent Space에서 시도.

Diffusion Models는 GAN의 한계를 넘어 이미지 생성·편집에서 뛰어난 성능을 보임.

3. Preliminaries

x: 실제 이미지

Latent Diffusion Model이 인코더 $x \rightarrow z_0$, 디코더 $z_0 \rightarrow \hat{x}$, denoising U-Net으로 구성됨.

타임스탬프 t 는 실제 이미지에서 파생된 latent 벡터가 각 단계에서 약간의 노이즈를 합성해 가우시안 분포로 매핑되는 diffusion 과정.

Denoising U-Net은 ϵ 추정하는 것.

4. Real Image Interpolation

4.1 Latent Interpolation

일반적으로 보간 시퀀스를 생성하기 위해서는 주어진 2개의 인풋 이미지에서 시작해 이미지 쌍을 반복적으로 보간함. parent 이미지의 쌍에 대해 latent 벡터에 shared 노이즈 추가, 보간하고 노이즈를 제거해 중간 이미지 생성. parent latent 벡터에 추가할 노이즈의 양은 smooth한 보간을 위해 parent가 시퀀스에서 가까이 있을 때 작아야 함. 멀리 있을 때는 LDM이 확률이 높고 노이즈가 커야함.

증가하는 타임스탬프를 지정하고 분리하는 구조를 통해 이미지를 분산하고 평균화해 이미지 생성. 각 parent 이미지 쌍에 개별적으로 노이즈를 추가하면서 이미지가 parent 이미지에 가까워지도록 하고 형제 이미지는 분리.

Interpolation type

slerp를 사용해 잠재 공간과 텍스트 임베딩 보간. 포즈 보간에는 선형 보간 사용.

Noise schedule

DDIM 샘플링 수행. Diffusion 과정이 최소 200개의 타임스탬프로 분할. 스케줄의 25% 미만으로 denoised latent 벡터는 parent 이미지의 알파 합성과 비슷. 65% 이상으로 생성된 이미지는 parent 이미지에서 크게 벗어날 수 있음.

4.2 Textual Inversion

사전 학습된 diffusion 모델은 특정 스타일의 고품질 출력을 생성하기 위해 텍스트 조건에 크게 의존. 각 이미지의 전체 내용, 스타일을 설명하는 텍스트가 주어지면 textual inversion을 적용해 임베딩을 이미지에 구체적으로 적용. 임의의 노이즈 레벨에서 잠재 벡터를 denoising 할 때 오차 최소화


$$\mathcal{L}(c_{\text{text}}) = \|\hat{\epsilon}_{\theta}(\alpha_t z_0 + \sigma_t \epsilon; t, c_{\text{text}}) - \epsilon\| ;$$

경사 하강법 100~500회 반복.

2개의 인풋 이미지에 대해 같은 초기 프롬프트 지정하지만 자동화된 접근 방식을 캡션 모델로 대체 가능. 긍정, 부정 텍스트 프롬프트가 모두 사용되고 최적화되며 각 이미지 쌍에 대해 프롬프트 공유.

4.3 Pose Guidance

2개의 이미지 간에 포즈가 크게 다르면 이미지 보간이 어렵고 팔다리, 얼굴이 여러개인 것 같은 이미지가 생성됨. LDM에 포즈 컨디셔닝 정보를 통합해 다른 포즈의 이미지 간에 그럴듯한 전환을 얻음.



두 이미지의 공유 키포인트 위치를 선형 보간해서 각 이미지의 중간 포즈를 얻음. 결과 포즈는 임의의 이미지 입력을 컨디셔닝하는 ControlNet을 사용해 LDM에 사용. 입력 이미지에 대해 잘못된 포즈가 예측되는 경우에도 포즈에 대한 컨디셔닝이 급격한 포즈 변경을 방지.



4.4 CLIP Ranking

LDM은 다양한 랜덤 시드를 사용해 다양한 품질의 출력 생성 가능. 하나의 잘못 생성된 이미지가 파생된 다른 모든 이미지의 품질을 손상시켜 실제 이미지 보간이 복잡해짐. 품질이 속도보다 중요한 경우 서로 다른 랜덤 시드를 이용해 여러 후보를 생성하고 다음 CLIP으로 순


위를 매김. 서로 다른 노이즈 벡터를 사용해 forward diffusion 단계를 반복하고 보간된 벡터의 노이즈를 제거하고 프롬프트로 디코딩된 이미지의 CLIP 유사도 측정. 사용자가 원하는 보간을 수동으로 선택하거나 특정 이미지에 대한 새 프롬프트, 포즈를 지정할 수 있는 interactive 모드로 변경 가능.

5. Experiments

5.1 Latent Interpolation

denoising 없이 보간, noisy 버전 보간, 부분적으로 denoised 된 버전, shared noise 없이 보간한 버전으로 실험

- Interpolate only: 단순 보간 방식은 입력 이미지의 잠재 코드를 단순히 보간해 이미지를 생성. Diffusion 과정을 거치지 않기 때문에 실패. 이 방식에서는 z_0 와 z_N 을 보간해 이미지를 생성, LDM의 복원된 잠재 공간이 구조화되어 있지 않아 제대로 된 이미지를 생성하지 못함
- Interpolate-denoise: 잠재 코드 보간, diffusion process 도입, Denoising 과정을 통해 이미지 생성
- Denoise-interpolate-denoise: 잠재 공간 보간의 한계를 극복하기 위해 두 번의 denoising 과정을 결합한 기법. 먼저 입력 이미지를 노이즈가 포함된 잠재 표현으로 변환하고, 잠재 공간에서 보간을 수행. 보간된 잠재 코드는 Diffusion 모델을 통해 denoise 과정을 거쳐 중간 이미지를 생성. 이후 추가적인 denoise를 통해 이미지 품질을 더욱 개선하고 자연스러운 전환 진행. 비구조적인 잠재 공간에서도 고품질의 보간 이미지를 생성하는 데 효과적.



Interpolation Scheme	FID	PPL
Interpolate only	436	56±8
Interpolate-denoise	179	172±32
Denoise-interpolate-denoise (DID)	169	144±26
DID w/o shared noise	199	133±22
Add noise-interpolate-denoise (ours)	214	193±27

5.2 Extensions

Interpolation schedule: uniform interpolation 스케줄 사용.

Adding Motion: 보간 이미지의 affine 변환과 결합



6. Conclusion

서로 다른 스타일의 이미지를 고품질로 보간하는 실제 이미지 보간 방식 소개함.

intermediate 프롬프트, 세그멘테이션, 경계 박스 등으로 인풋에 conditioning 하는 방식들과 함께 사용.

한계: 스타일과 레이아웃의 차이가 클때 보간 실패할 수 있음.