



Review 1 : Deep Sparse Rectifier Neural Networks

#DL-Basic

논문 링크 : [Deep Sparse Rectifier Neural Networks](#)

1. Introduction

'Deep Sparse Rectifier Neural Networks'에 대해 자세히 설명하면서, 생물학적 뉴런 모델과 기계 학습 모델 간의 차이를 줄이는 방법을 제시합니다. 이 연구는 rectifying 활성화 함수의 사용이 심층 신경망의 훈련에 미치는 긍정적인 영향을 강조하며, 더 나아가 이러한 방식이 기존의 hyperbolic tangent 네트워크보다 성능이 뛰어날 수 있음을 보여줍니다. 이 논문은 심층 신경망의 훈련을 개선하고 성능 차이를 줄이는 데 필요한 중요한 통찰력을 제공합니다.

2. Contents

1. 🇰🇷 생물학적 뉴런 모델과 심층 네트워크 성능 비교

: 로지스틱 시그모이드 뉴런은 생물학적으로 더 타당하지만, 하이퍼볼릭 탄젠트 뉴런은 다층 신경망 훈련에 더 효과적이다. 이 논문에서는 Rectifier Neural Networks이 생물학적 뉴런의 모델로서 더욱 우수한 성능을 보이며 하이퍼볼릭 탄젠트 네트워크보다 동등하거나 더 나은 성능을 낸다는 점을 보여준다.

: Rectifier Neural Networks은 희소 표현을 생성하며, 자연적으로 희소한 데이터에 적합하다. 또한, 반지도 학습에서 unlabeled 데이터를 활용할 수 있지만, 깊은 Rectifier NN는 큰 라벨 데이터셋을 이용한 전적으로 지도 학습 작업에서 사전 훈련 없이도 최상의 성능에 도달할 수 있다.

2. 신경망 모델과 딥러닝의 간극 해소

: 기계 학습 연구자와 계산 신경 과학자들이 사용하는 신경망 모델 간에는 여러 차이가 존재하며, 이는 전자의 목표가 새로운 예제에 잘 일반화되는 효율적인 학습자를 얻는 반면, 후자

는 신경 과학 데이터를 추상화하여 생물학적 실험에 대한 예측을 제공하는 것에 있다는 점에서 차이가 있다.

: 두 모델 간의 간극을 해소하기 위해 rectifier 활성화 함수인 $\max(0; x)$ 를 제안하며, 이는 깊은 아키텍처에서 흥미로운 학습 행동을 나타낸다. 이 논문은 비지도 학습을 통해 초기화된 각 레이어의 중요성을 강조하며, 희소성을 촉진하기 위해 L1 정규화를 사용할 것을 제안한다.

또한 우리는 이미지 분류 기준에서 정류 활성화 함수와 하이퍼볼릭 탄젠트의 광범위한 경험적 비교를 수행하며, 이 연구가 심리 분석과 같은 텍스트 응용에도 적용된다는 점을 언급한다.

이 알고리즘은 대량의 비표기 데이터가 주어질 경우 반지도 학습 문제에서도 이점을 제공할 수 있으며, 자연과학의 신경세포 반응과의 유사성을 통해 기계 학습 및 신경 과학 간의 간극도 일부 해소하게 된다.

3. 신경망과 머신러닝의 비선형 활성화 함수 비교

생물학적 신경망 모델과 머신러닝 모델 간의 주요 차이점은 비선형 활성화 함수와 관련이 있다. 신경세포는 정보를 희소하고 분산된 방식으로 인코딩하며, 활성화 함수는 자연스러운 활성화와 억제를 구현해야 한다.

희소성은 컴퓨터 신경과학과 머신러닝뿐만 아니라 통계와 신호 처리에서도 중요한 요소이다. 이 기술들은 효율적인 변수 크기 표현을 가능하게 하며, 이는 입력 변동에 대해 강건함을 발휘한다. 또한 희소성 표현은 선형 분리가 가능하고, 원래의 데이터 형식을 반영할 수 있다.

4. 3 딥 렉티파이어 네트워크

렉티파이어 뉴론에 관한 연구에 따르면, 피질 뉴런은 최대 포화 상태에 잘 있지 않으며, 이들의 활성화 함수는 렉티파이어로 근사될 수 있다. 대부분의 이전 연구는 렉티파이어 활성화 함수를 사용하는 순환 네트워크와 관련이 있다. 렉티파이어 함수는 one-sided로, 신호 대칭성이나 반대칭성을 강요하지 않으며, 흥분성 입력 패턴의 반응은 0이 된다.

하지만 매개변수를 공유하는 두 개의 렉티파이어 유닛을 결합함으로써 대칭이나 반대칭을 얻을 수 있다. 렉

티파이어 활성화 함수는 네트워크가 희소 표현을 쉽게 얻도록 하며, 무작위 초기화 후 약 50%의 숨겨진 유닛의 출력 값이 0인 경우가 발생할 수 있다. 이러한 희소성은 수학적 이점과 생물학적으로 논리적인 장점을 제공한다.

5. 비선형 함수와 최적화의 잠재적 문제

$\tanh(x)$ 비선형성은 부호 비대칭성을 강제하며, 이로 인해 입력에 대해 선형적으로 모델링이 가능하다. 그러나 0에서의 하드 포화가 최적화에 부정적인 영향을 미칠 수 있으며, 이로

인해 기울기 역전파가 차단될 수 있다. 이 문제를 해결하기 위해 소프트플러스 활성화 함수를 사용해 볼 수 있으며, 이는 더 부드러운 비선형성을 제공한다.

하지만 실험 결과는 하드 제로가 감독 학습에 실제로 도움이 된다고 제안하며, 일부 경로에서는 기울기가 전파될 수 있음을 가정하면 최적화가 더 용이하다고 가정할 수 있다.

6. unsupervised 사전 학습의 다양한 전략

자동 인코더 변형에서 학습한 희소 표현이 심층 아키텍처 훈련에 매우 유용하다는 점에서 본 논문은 영감을 받았다. 하지만, 스택된 잡음 제거 자동 인코더에 직류 활성화 함수를 도입할 때 몇 가지 어려움이 발생할 수 있다.

첫째, 직류 함수의 임계값 아래에서의 강한 포화는 복원 단위에 적합하지 않다.

둘째, 직류 활성화의 무한한 행동도 고려해야 하며, 복원 함수와 여러 가지 실험 전략도 소개되었다.

첫 번째 전략은 복원층에 소프트플러스 활성화 함수를 사용하는 것이며, 두 번째는 활성화 값을 0과 1 사이로 조정하고 시그모이드 활성화 함수를 사용하는 것이다.

7. 연구에서 다른 비교

a. 이미지 인식 실험 설정 및 결과

이 연구에서는 여러 가지 이미지 데이터셋을 고려했으며, 각 데이터셋은 훈련 세트, 검증 세트, 테스트 세트로 구성되어 있다. 데이터셋의 특징은 MNIST(50k/10k/10k, 28×28 크기의 숫자 이미지, 10 클래스), CIFAR10(50k/5k/5k, 32×32 RGB 이미지, 10 클래스), NISTP(81,920k/80k/20k, 32×32 문자 이미지, 62 클래스) 등이며, 일반적으로 더 큰 데이터셋이 더 어려운 경향이 있다. 테스트 오류에 대한 결과는 Rectifier, Tanh, Softplus 네트워크의 성능을 비교할 수 있으며, 사전 훈련이 있는 경우와 없는 경우의 결과도 나타나 있다.

진행된 실험에서는 레이어 수와 유닛 수에 대한 강력한 결과 및 활성화 함수에 따른 성능 차이를 보여준다.

Semi-supervised 환경에서의 실험 결과, Rectifier 네트워크는 라벨이 있는 데이터와 라벨이 없는 데이터를 최대한으로 활용할 수 있음을 확인할 수 있다.

b. 감정 분석을 위한 딥러닝 연구

Nair와 Hinton(2010)은 이미지 관련 작업에서 리니어 유닛의 효율성을 입증하였다. 그들은 네트워크의 기능이 입력의 강도 변화에 대해 선형적으로 변이함을 설명하며 이를 언급하였다. 이러한 관점에서 리니어 활성화는 이미지 데이터에 주로 유용하다고 제안할 수 있다. 최근 연구(Zhou et al., 2010)는 이진 유닛을 가진 딥 빌리프 네트워크가 감정 분석을 위한 최신 기법과 경쟁력을 가진다고 보여준다.

이것은 딥러닝이 텍스트 작업에 적합함을 나타내며, 리니어 유닛의 행동을 새로운 양식으로 관찰하는 데 이상적이다.

3. conclusion : 신경망에서의 희소성과 활성화 함수의 역할

- 희소성과 주로 선형 방식으로 작동하는 뉴런은 생물학적으로 더 그럴듯한 심층 신경망을 통해 통합될 수 있다.
- 특히, Rectifier 유닛은 비지도 사전 학습과 사전 학습 없음 사이의 격차를 줄이는 데 도움을 주며, 이는 훈련 중 더 나은 최소값을 찾는 데 기여할 수 있다.
- 이 발견은 네 가지 서로 다른 규모의 이미지 분류 데이터셋에 대해 검증되었으며, 그럼에도 불구하고 기울기의 제로나 파라미터화의 비정상적 문제와 같은 내재적인 문제를 가지고 있다.
- 희소성이 50%에서 80%에 이르는 희소 신경망이 생성되었으며, 이는 직관적으로 뇌의 95%에서 99%의 희소성과의 연결을 설명할 수 있다.
- 또한, Rectifier 활성화 함수는 감정 분석과 같은 데이터의 희소성이 큰 작업에 매우 적합하다는 것이 입증되었다.