

Flamingo: a Visual Language Model for Few-Shot Learning

00 Abstract

Flamingo

- 새로운 문제에 적은 수의 annotated 데이터를 가지고 좋은 성능을 낼 수 있는 multi modal 모델
- Visual Language Model **VLM** : 비전 모델 + 언어 모델, 다양한 시각 및 텍스트 데이터 처리 가능
 - multi modal : 텍스트와 이미지 사이에서 상호작용하며 이해하는 것이 가능 → visual question-answering, captioning task 등에 효과적
 - sequential 특징 처리 → 비디오까지 처리 가능
- **Few-shot** : 적은 데이터를 추가하는 것으로 새로운 테스트에 적응하도록 하는 것이 가능

01 Introduction

intelligence - ability to quickly learn to perform a new task given a short instruction, 새로운 태스크를 해결하는 방법을 빠르게 학습.

→ 기존의 방식 : 대량의 데이터로 pre-training, 이후 해결할 문제에 맞도록 **fine-tuning**

- **resource intensive** : 학습 시 대량의 데이터 필요, 또 추가적인 데이터로 수많은 하이퍼파라미터를 조정해야함

→ **zero-shot** : fine tuning 없이 새로운 태스크에 적응






- classification에만 적용 가능, 새로운 언어를 생성하는 능력이 없음. visual question-answering, captioning task 등에 적용이 어렵다.

→ visually-conditioned language generation : 이미지, 비디오 등 시각적 입력을 받아 언어 생성

- 발전 중, 하지만 아직 적은 수의 데이터로 학습 어려움

Flamingo (VLM)

- Few-shot : 적은 수의 예시로 새로운 작업에 적응 (16 task 중 6 tasks에서 적은 학습 데이터로 좋은 성능을 보임)

Input Prompt					Completion
	This is a chinchilla. They are mainly found in Chile.		This is a shiba. They are very popular in Japan.		This is → a flamingo. They are found in the Caribbean and South America.
	What is the title of this painting? Answer: The Hallucinogenic Toreador.		Where is this painting displayed? Answer: Louvres Museum, Paris.		What is the name of the city where this was painted? Answer: → Arles.
	Output: "Underground"		Output: "Congress"		Output: → "Soulome's"
	2+1=3		5+6=11		→ 3x6=18
	Output: A propaganda poster depicting a cat dressed as French emperor Napoleon holding a piece of cheese.		Output: A pink room with a flamingo pool float.		Output: → A portrait of Salvador Dali with a robot head.
	Les sanglots longs des violons de l'automne blessent mon cœur d'une langueur monotone.		Pour qui sont ces serpents qui sifflent sur vos têtes?		→ Je suis un cœur qui bat pour vous.
	pandas: 3		dogs: 2		→ giraffes: 4
I like reading		, my favourite play is Hamlet. I also like		, my favorite book is	→ Dreams from my Father.
					What happens to the man after hitting the ball? Answer: → he falls down.

			
This is a picture of two teddy bears on the moon.		This is an apple with a sticker on it.	This is a cityscape. It looks like Chicago.
What are they doing?		What does the sticker say?	What makes you think this is Chicago?
They are having a conversation.		The sticker says "iPod".	I think it's Chicago because of the Shedd Aquarium in the background.
What object are they using?		Where is the photo taken?	
It looks like a computer.		It looks like it's taken in a backyard.	What about this one? Which city is this and what famous landmark helped you recognise the city?
Is this surprising?		Do you think it is printed or handwritten?	This is Tokyo. I think it's Tokyo because of the Tokyo Tower.
Yes, it is surprising.		It looks like it's handwritten.	
Why is this picture surprising to you?		What color is the sticker?	
I think it is surprising because teddy bears are not usually found on the moon.		It's white.	

Figure 1: Selected examples of inputs and outputs obtained from *Flamingo-80B*. *Flamingo* can rapidly adapt to various image/video understanding tasks with few-shot prompting (top). Out of the box, *Flamingo* is also capable of multi-image visual dialogue (bottom). More examples in

- LMs (Large Language Models) = 대형 언어 모델로부터 영감을 받음. Few-shot에서 좋은 성능 : 텍스트(이미지, 비디오) 의 예시 또는 질의 → 출력 생성하는 모델

- 차이점) 플라밍고는 text + images/videos 의 multi modal input을 기반으로 텍스트 생성
- Visual model(Perceiver - 입력된 데이터로부터 small fixed number of visual tokens 생성 및 처리) + LMs (대량의 텍스트 데이터로 학습)
- Flamingo - trained without using any data annotated for ML purpose ⇒ 가공되지 않은, 그냥 수집된 데이터로 학습

Contribution

- Flamingo : VLM. multimodal 입력 처리 및 open-ended text 생성 가능한 모델 소개
- Flamingo (Few-shot Learning) 평가 : estimate unbiased few-shot performance
- 32개의 예시만으로 16개 중 6개의 태스크에 최고 성능. VQAv2, VATEX, VizWiz, MSRVTQA, HatefulMemes 벤치마크 - 좋은 성능(fine-tuning)

02 Approach

: This section describes Flamingo




Figure 3: **Flamingo architecture overview.** Flamingo is a family of visual language models (VLMs) that take as input visual data interleaved with text and produce free-form text as output.

perceiver resampler : vision encoder → spatio-temporal features → a fixed number of visual tokens

Frozen LM : cross-attention 통해 visual information 통합 → next token prediction
(이때 조건부 확률 계산)

$$p(y|x) = \prod_{\ell=1}^L p(y_{\ell}|y_{<\ell}, x_{\leq \ell}),$$

GPT-3과 유사한 방식으로 few-shot learning → 적은 수의 예시로 각 태스크에 적응

2.1 Visual processing and the Perceiver Resampler

Visual Encoder : from px to features

- Normalizer-Free ResNet, ver F6 : 이미지-텍스트 매칭시키는 방식으로 학습
 - Contrastive Learning : contrastive loss, 데이터 쌍으로 이미지-텍스트의 관계를 효과적으로 학습
- 이미지 : (features) 2D spatial grid → flattened 1D sequence
- 비디오 : 초당 1 frame, 프레임별로 인코딩. 3D spatio-temporal(시공간적) grid → temporal embedding → flattened 1D

Perceiver Resampler : from varying-size large feature maps to few visual tokens

- visual feature → 고정된 수(여기서는 64)의 비주얼 토큰으로 변환
- vision-text cross-attention ⇒ visual - text 상호작용
- plain Transformer, MLP보다 효과적

2.2 Conditioning frozen language models on visual representations

텍스트 생성은 Transformer Decoder에서. Perceiver Resampler에서 생성한 visual token을 입력으로 사용

Interleaving new GATED XATTN-DENSE layers within a frozen pretrained LM.

- 사전훈련된 LM block에 gated corss-attention dense block(새로 처음부터 훈련)을 삽입함




Figure 4: **GATED XATTN-DENSE layers.** To condition the LM on visual inputs, we insert new cross-attention layers between existing pretrained and frozen LM layers. The keys and values in these layers are obtained from the vision features while the queries are derived from the language inputs. They are followed by dense feed-forward layers. These layers are *gated* so that the LM is kept intact at initialization for improved stability and performance.

- tanh-gating mechanism : 새로 추가된 레이어의 출력에 $\tanh(\alpha)$ 곱하여 기존의 입력에 더함 $\Rightarrow$ 훈련 초기 안정성 및 성능 향상

Varying model sizes

- 파라미터 수에 따라 Flamingo-3B, Flamingo-9B, Flamingo-80B
- LMs와 vision-text GATED XATTN-DENSE module 크기는 키우지만, **Vision Encoder와 Perceiver Resampler의 크기는 고정**
 - 계산 효율 및 복잡도 조정 가능

2.3 Multi-visual input support: per-image/video attention masking

$\Rightarrow$ 직전에 바로 등장한 이미지를 참조하며 순차적으로 이미지 처리

$\Rightarrow$ 한 번에 하나의 이미지를 직접 참조 하지만 self-attention 통해 이전 이미지 기억 가능(문맥 파악 가능)

계산량을 줄여 효율을 높임

2.4 Training on a mixture of vision and language datasets

플라밍고는 세 가지 인터넷 웹으로부터 수집된 세 가지 데이터셋으로 훈련된다.

M3W: Interleaved image and text dataset

- MultiModal MassiveWeb, 4300만 개의 웹 페이지
- HTML 문서에서 DOM기반으로 특정 태그(<image>, <EOC>(End of Chunk))를 추가하여 필요한 데이터를 추출
- 각 문서에서 256 토큰으로 랜덤 서브시퀀스 샘플링 - 각각 최대 5개의 이미지 선택

Pairs of image/video and text

- ALIGN dataset : 이미지 - alt-text(대체 텍스트, 이미지를 보지 못할 때 설명용으로 사용) 쌍으로 구
- LTIP dataset : 하이퀄리티의 자세한 설명 - 이미지 쌍. 새로 수집한 데이터셋임
- VTP dataset : 비디오 - 텍스트 쌍. 짧은 비디오와 설명 사용
- M3M과 형식 통일 위해 image, EOC 태그 추가하여 처리

Multi-objective training and optimisation strategy

- minimizing a weighted sum of per-dataset expected negative log-likelihoods of text, given the visual inputs.
- round robin, 모든 데이터셋에 대한 그래디언트 축적하여 훈련

$$\sum_{m=1}^M \lambda_m \cdot \mathbb{E}_{(x,y) \sim \mathcal{D}_m} \left[- \sum_{\ell=1}^L \log p(y_{\ell} | y_{<\ell}, x_{\leq \ell}) \right],$$

2.5 Task adaptation with few-shot in-context learning

- in-context learning : 이미지/비디오-텍스트 쌍(support example pairs)의 인풋을 넣어 프롬프트 생성
- 평가
 - Open-ended : beam search 활용하여 텍스트 생성
 - Close-ended : log-likelihood 활용
 - zero-shot 일반화를 위해 두개의 텍스트 입력, 거기에 상응하는 이미지는 X

03 Experiments

- 목표 : 다양한 태스크에 빠르게 적응시키기
- 16 개의 multimodal image/video and language benchmark
 - COCO, OKVQA, VQAv2, MSVDQA, VATEX : 모델의 디자인 검증, DEV(Development) set 벤치마크에 사용. biased 가능
 - 나머지 11 벤치마크는 unbiased 위해 진행 - spanning captioning, video question-answering, as well as some less commonly explored capabilities such as visual dialogue and multi-choice question-answering tasks.
 - 여기에서만 validation support, validation query, test support, test query 사용
 - 평가를 위한 하이퍼 파라미터는 고정.

3.1 Few-shot learning on vision-language tasks

Method	FT	Shot	OK VQA (I)	VQA2 (I)	COCO (I)	MSVDQA (V)	VATEX (V)	VizWiz (I)	Flick30K (I)	MSRVTQA (V)	iVQA (V)	YouCook2 (V)	STAR (V)	VisDial (I)	TextVQA (I)	NextQA (I)	HatefulMemes (I)	RareAct (V)
Zero/Few shot SOTA	✗	(X)	[34] 43.3 (16)	[114] 38.2 (4)	[124] 32.2 (0)	[58] 35.2 (0)	-	-	-	[58] 19.2 (0)	[135] 12.2 (0)	-	[143] 39.4 (0)	[79] 11.6 (0)	-	-	[85] 66.1 (0)	[85] 40.7 (0)
Flamingo-3B	✗	0	41.2	49.2	73.0	27.5	40.1	28.9	60.6	11.0	32.7	55.8	39.6	46.1	30.1	21.3	53.7	58.4
	✗	4	43.3	53.2	85.0	33.0	50.0	34.0	72.0	14.9	35.7	64.6	41.3	47.3	32.7	22.4	53.6	-
	✗	32	45.9	57.1	99.0	42.6	59.2	45.5	71.2	25.6	37.7	76.7	41.6	47.3	30.6	26.1	56.3	-
Flamingo-9B	✗	0	44.7	51.8	79.4	30.2	39.5	28.8	61.5	13.7	35.2	55.0	41.8	48.0	31.8	23.0	57.0	57.9
	✗	4	49.3	56.3	93.1	36.2	51.7	34.9	72.6	18.2	37.7	70.8	42.8	50.4	33.6	24.7	62.7	-
	✗	32	51.0	60.4	106.3	47.2	57.4	44.0	72.8	29.4	40.7	77.3	41.2	50.4	32.6	28.4	63.5	-
Flamingo	✗	0	50.6	56.3	84.3	35.6	46.7	31.6	67.2	17.4	40.7	60.1	39.7	52.0	35.0	26.7	46.4	60.8
	✗	4	57.4	63.1	103.2	41.7	56.0	39.6	75.1	23.9	44.1	74.5	42.4	55.6	36.5	30.8	68.6	-
	✗	32	57.8	67.6	113.8	52.3	65.1	49.8	75.4	31.0	45.3	86.8	42.2	55.6	37.9	33.5	70.0	-
Pretrained FT SOTA	✓	(X)	54.4 [34] (10K)	80.2 [140] (444K)	143.3 [124] (500K)	47.9 [28] (27K)	76.3 [153] (500K)	57.2 [65] (20K)	67.4 [150] (30K)	46.8 [51] (130K)	35.4 [135] (6K)	138.7 [132] (10K)	36.7 [128] (46K)	75.2 [79] (123K)	54.7 [137] (20K)	25.2 [129] (38K)	79.1 [62] (9K)	-

Table 1: **Comparison to the state of the art.** A *single* Flamingo model reaches the state of the art on a wide array of image (I) and video (V) understanding tasks with few-shot learning, significantly outperforming previous best zero- and few-shot methods with as few as four examples. More importantly, using only 32 examples and without adapting any model weights, Flamingo *outperforms* the current best methods – fine-tuned on thousands of annotated examples – on seven tasks. Best few-shot numbers are in **bold**, best numbers overall are underlined.

- 16 벤치마크에서 거의 기존 방식을 능가
- 태스크당 4개의 예시만으로 쉽게 적응. 큰 데이터로 fine-tuning된 모델과도 경쟁력있음
- 일반화 성능도 좋음
- 큰 모델일수록, shot이 늘어날 수록 성능 개선.

3.2 Fine-tuning Flamingo as a pretrained vision-language model

Method	VQAV2		COCO	VATEX	VizWiz		MSRVTQA	VisDial		YouCook2	TextVQA		HatefulMemes
	test-dev	test-std	test	test	test-dev	test-std	test	valid	test-std	valid	valid	test-std	test seen
✗ 32 shots	67.6	-	113.8	65.1	49.8	-	31.0	56.8	-	86.8	36.0	-	70.0
✗ Fine-tuned	82.0	82.1	138.1	84.2	65.7	65.4	47.4	61.8	59.7	118.6	57.1	54.1	86.6
SotA	81.3 [†]	81.3 [†]	149.6[†]	81.4 [†]	57.2 [†]	60.6 [†]	46.8	75.2	75.4[†]	138.7	54.7	73.7	84.6 [†]
	[133]	[133]	[119]	[153]	[65]	[65]	[51]	[79]	[123]	[132]	[137]	[84]	[152]

Table 2: **Comparison to SotA when fine-tuning Flamingo.** We fine-tune *Flamingo* on all nine tasks where *Flamingo* does not achieve SotA with few-shot learning. *Flamingo* sets a new SotA on five of them, outperforming methods (marked with [†]) that use tricks such as model ensembling or domain-specific metric optimisation (e.g., CIDEr optimisation).

- 사전훈련된 vision-lang모델 파인튜닝 → 성능개선
 - 파인튜닝 후 최신 성능 능가
- 위는 주식 예산에 제한을 두지 않고 파인튜닝 한 결과.

- 짧은 훈련 텀, 비전모델 백본 해제로 해상도 향상

3.3 Ablation studies

Ablated setting	Flamingo-3B original value	Changed value	Param. count ↓	Step time ↓	COCO CIDEr↑	OKVQA top1↑	VQAv2 top1↑	MSVDQA top1↑	VATEX CIDEr↑	Overall score↑
Flamingo-3B model			3.2B	1.74s	86.5	42.1	55.8	36.3	53.4	70.7
(i)	Training data	All data	w/o Video-Text pairs	3.2B	1.42s	84.2	43.0	53.9	34.5	67.3
			w/o Image-Text pairs	3.2B	0.95s	66.3	39.2	51.6	32.0	60.9
			Image-Text pairs → LAION	3.2B	1.74s	79.5	41.4	53.5	33.9	66.4
			w/o M3W	3.2B	1.02s	54.1	36.5	52.7	31.4	53.4
(ii)	Optimisation	Accumulation	Round Robin	3.2B	1.68s	76.1	39.8	52.1	33.2	62.9
(iii)	Tanh gating	✓	✗	3.2B	1.74s	78.4	40.5	52.9	35.9	66.5
(iv)	Cross-attention architecture	GATED XATTN-DENSE	VANILLA XATTN GRAFTING	2.4B	1.16s	80.6	41.5	53.4	32.9	66.9
				3.3B	1.74s	79.2	36.1	50.8	32.2	63.1
(v)	Cross-attention frequency	Every	Single in middle	2.0B	0.87s	71.5	38.1	50.2	29.1	59.8
			Every 4th	2.3B	1.02s	82.3	42.7	55.1	34.6	68.8
			Every 2nd	2.6B	1.24s	83.7	41.0	55.8	34.5	68.2
(vi)	Resampler	Perceiver	MLP	3.2B	1.85s	78.6	42.2	54.7	35.2	66.6
			Transformer	3.2B	1.81s	83.2	41.7	55.6	31.5	66.7
(vii)	Vision encoder	NFNet-F6	CLIP ViT-L/14	3.1B	1.58s	76.5	41.6	53.4	33.2	64.9
			NFNet-F0	2.9B	1.45s	73.8	40.5	52.8	31.1	62.7
(viii)	Freezing LM	✓	✗ (random init)	3.2B	2.42s	74.8	31.5	45.6	26.9	57.8
			✗ (pretrained)	3.2B	2.42s	81.2	33.7	47.4	31.0	62.7

Table 3: **Ablation studies.** Each row should be compared to the baseline Flamingo run (top row). Step time measures the time spent to perform gradient updates on all training datasets.

Importance of the training data mixture

- M3W 제거시 17%의 성능 저하 발생 : need for different types of datasets.
- image-text pair 제거 : 9.8% 성능 저하
 - IPT(image-text) → LAION-400M(publicly available) 교체시에도 약간의 성능 저하
- video-text pair 제거 : 비디오 관련 태스크 성능 저하
- 다양한 유형의 데이터셋 필요

Visual conditioning of the frozen LM

- LM 결합 방식
- 0-initialized tanh gating 제거 → frozen LM 결합에 사용.
 - 사용하지 않을 때 4.2% 성능 감소 → 0-initialized tanh gating이 훈련중 안정성
- VANILLA XATTN : 기본 cross-attention

- GRAFTING : frozen LM 에 추가 레이어 없이 self-attention&cross-attention 처음 부터 학습
- 이 논문에서의(Flamingo의) GATED XATTN-DENSE가 가장 좋은 성능

Compute/Memory vs. performance trade-offs

- GATED XATTN-DENSE : 모든 블록이 아닌 매번 4번째 블록에 추가 할 때 훈련 속도 빨라짐(성능 1.9% 감소) → trade off 균형
 - 데이터 큰 -08B 모델에서는 매 7번째 층마다 블록 추가

Vision encoder

- NFNet-F6 vision encoder : contrastive learning
- CLIP ViT-L/14
- 두 인코더 중 NFNet-F6에서 좋은 성능
 - vision backbone 사용의 중요

Freezing LM components prevents catastrophic forgetting

- freeze 하지 않을 때 12.9% 성능 감소 : catastrophic forgetting 발생 때문
 - LM의 fine-tuning시에도 catastrophic forgetting 발생
- catastrophic forgetting으로 인한 성능 저하를 막기 위해 frozen LM 사용

04 Related work

Language modelling and few-shot adaptation

- Transformer 이후 : 대규모 데이터로 사전 훈련 → 태스크에 맞춰 adaptation
- Flaminge(70B Chinchilla) 사용
- few-shot
 - small adapter modules
 - LM 일부만 fine tuning

- incontext 예시 추가
- prompt optimization
- meta-learning 보다 간단히 새로운 태스크에 적응

When language meets vision

- BERT(언어 모델) → vision-lang 모델에 영향
- Flamingo는 fine tuning이 필요 없다는 점에서 다른 모델과의 차별
- contrastive learning 사용
- 자기회귀적 텍스트 생성 : 기존 접근법과 유사
- freeze → catastrophic forgetting 방지 하는 접근법 사용
 - 하지만 플라밍고는 학습 가능한 레이어를 추가

Web-scale vision and language training datasets

- 손수 주석을 단 데이터셋 - 비용이 크고, 사이즈가 작다
- 자동 크롤링 사용
- 웹페이지 전체를 하나의 데이터로 활용
- CM3과 다르게 텍스트 예측 단순화

05 Discussion

- 한계
 - LM의 약점을 그대로 상속 → hallucination
 - 시퀀스 길어질 때 성능 저하
 - 분류에 대한 성능은 최신 contrastive model보다 떨어짐
 - 샷이 늘어날수록 비용 증가, 성능 저하
- 사회적 영향
 - 데이터 부족 문제 해결
 - 성별, 인종 등 사회적 편향 완화
- 결론

- 최소한의 훈련으로 이미지/비디오 태스크에 적응 가능한 모델 제안
- interactive 능력
- 시각적 모델과 언어 모델의 결합