

Training language models to follow instructions with human feedback

00 Abstract

- 사용자에게 도움이 되는 - 사용자의 피드백 (파인튜닝, 지시) 통해 사용자의 의도와 일치하는 모델로 align
- 강화학습 바탕으로 파인튜닝 → Instruct GPT
- Instruct GPT : 진실성 개선, 유해 출력 감소. 공개 NLP 데이터셋에서 성능 저하 감소

01 Introduction

the language modeling objective is misaligned.

없는 사실을 만들어내거나, 편향적이고 유해한 텍스트 생성 ⇒ 사용자가 의도하지 않은 행동이 의도하지 않은 행동 피하기 + *helpful & honest & harmless* 유지

RLHF - reinforcement from human feedback

- 모델과 사용자 의도의 정렬(aligning) 위해, GPT-3 기반으로 파인튜닝에 사용
- 40명의 사람을 고용하여 reward signal 생성
- training
 - human-written demonstrations 시범 데이터 수집
 - supervised learning 통해 baseline (기초 모델) 훈련
 - 모델 출력에 대한 비교 데이터 수집
 - RM (reward model) 훈련 및 활용
 - PPO algorithm → fine tuning

Labelers significantly prefer InstructGPT outputs over outputs from GPT-3.

레이블러(사람)은 InstructGPT가 100배 적은 파라미터를 가지고 있음에도 더 선호되는 출력이 생성되고 지시에 대한 제약을 잘 지킨다고 평가.

둘의 큰 차이점은 인간이 직접 생성한 데이터를 기반으로 파인튜닝 되었다는 점이다.

InstructGPT models show improvements in truthfulness over GPT-3.

TruthfulQA benchmark → 더 진실성 있고 유익한 답변 생성

closed-domain (출력이 입력에 존재하지 않는 정보를 포함해서는 안된다)

GPT-3과 비교했을 때 21% vs. 41% hallucination rate

InstructGPT shows small improvements in toxicity over GPT-3, but not bias

toxicity(독성, 유해하거나 공격적인 텍스트) - RealToxicityPrompts 데이터셋 사용시 25% 적은 독성 출력을 생성했지만, Winogender와 CrowSpairs에서 큰 향상을 보이지 않았다.

We can minimize performance regressions on public NLP datasets by modifying our RLHF fine-tuning procedure

RLHF 파인튜닝 중, 특정 NLP 데이터셋(SQuAD, DROP, HellaSwag, WMT 2015 French to English translation)에서 GPT-3 에 비해 성능이 저하됨

⇒ alignment tax.

사용자가 제공하는 alignment procedure(정렬 절차)가 성능 저하 초래

PPO updates with updates that increase the log likelihood of the pretraining distribution (PPO-ptx) 로 성능 저하 보완

Our models generalize to the preferences of "held-out" labelers that did not produce any training data.

훈련할 때 데이터를 제공하지 않은 held-out(보류된) 레이블러의 선호도에도 일반화 된다.
이들도 Instruct GPT 출력이 더 선호된다고 평가
더 넓은 범위의 사용자 그룹에서의 수행에 대해서는 연구 필요

Public NLP datasets are not reflective of how our language models are used

공개된 NLP 데이터셋은 우리의 언어 모델이 실제로 사용되는 방식과 일치하지 않

InstructGPT models show promising generalization to instructions outside of the RLHF fine-tuning distribution

다른 지시에도 유망한 일반화 성능을 보인다.

→ 코드 요약, 코드에 대한 질의응답 등에 대한 지시를 잘 따름

다양한 언어로 구성된 지시 또한 따를 수 있음

적은 지시에도 일부 alignment 가능

InstructGPT still makes simple mistakes.

지시를 따르지 못하거나, 거짓을 만들거나, 단순 질문에 긴 해명 답변을 출력하거나, 전제에 오류를 가지는 등의 실수 할 수 있

02 Related work

Research on alignment and learning from human feedback.

⇒ **RLHF** : 인간의 의도를 더 잘 포함시키기 위해 human feedback 추가. 사람의 피드백을 보상으로 사용

- 원래 Atari 게임에서 모델을 훈련시키기 위해 개발됨 ⇒ 텍스트 요약 위해 사용
- dialogue, translation, semantic parsing, story generation, review generation, evidence extraction 에 효과
- what it means for language models to be aligned has also received attention : alignment 에 대한 정의 연구

Training language models to follow instructions.

- crosstask generalization. LM을 광범위의 공개 NLP dataset 에서 파인튜닝 - 다른 task 에서 평가
- instruction 으로 파인튜닝하면 zero-shot, few-shot 학습에서 성능이 향상
- instruction following for navigation 과 관련된 분야

Evaluating the harms of language models.

- real world 에 배포되었을 때 위험을 최소화하기 위함
 - 편향된 출력 생성 위험
 - 개인정보 유출 위험
 - misinformation 생성 위험
 - 사용자의 악의적 사용
- dialog systems 에서..
- 고정관념, 사회적 편향, 독성을 평가하기 위한 벤치마크 구축 관련 분야의 성장
 - 성능을 해치지 않는 선의의 개입

Modifying the behavior of language models to mitigate harms.

- fine-tune LMs on a small, value-targeted dataset - 가치를 더 잘 따를 수 있게
- 필터링 된 데이터셋 사용
 - data filtering, n-gram, word blocking
 - human-in-the-loop data collection
- 편향 완화 위해 embedding regularization, data augmentation, null space projection 등 사용

03 Methods and experimental details

3.1 High-level methodology

Our methodology follows that of Ziegler et al. (2019) and Stiennon et al. (2020)




Figure 2: A diagram illustrating the three steps of our method: (1) supervised fine-tuning (SFT), (2) reward model (RM) training, and (3) reinforcement learning via proximal policy optimization (PPO) on this reward model. Blue arrows indicate that this data is used to train one of our models. In Step 2, boxes A-D are samples from our models that get ranked by labelers. See Section 3 for more details on our method.

1. 시범 데이터 수집 & supervised fine-tuning

- labeler 가 입력 프롬프트에 대한 시범 답변 제공
- 이 데이터 활용하여 지도 학습 방식으로 파인튜닝

2. 비교 데이터 수집 & RM 훈련

- 모델의 출력 간 비교 데이터셋 수집 → 어떤 출력이 선호되는지 라벨링
- 선호 출력 활용하여 RM 출력

3. PPO 활용하여 RM 최적화

- PPO 알고리즘 사용

step2 & step3 반복되며 데이터 수집-훈

3.2 Dataset

프롬프트 데이터셋은 주로 text prompts submitted to the OpenAI API. 이전 버전의 InstructGPT 모델 - Playground interface(고객에게 그들의 데이터가 모델 훈련에 사용될 수 있음을 고지)

개인 식별 정보 활용하여 필터링 및 user ID 별로 데이터 수집

labeler 는 세 가지 종류의 프롬프트 작성

- Plain : 임의의 작업, 작업에 다양성 포함
- Few-shot : 어떤 지침을 주고 그에 대한 QA 요
- User-based : OpenAI API에 대한 대기 리스트 신청서에 명시된 여러 사용 사례에 대해 레이블러가 해당하는 프롬프트를 작성

생성한 데이터셋

- SFT dataset : SFT 모델 훈련 - 레이블러 시범 데이터셋 사용
- RM dataset : RM 모델 훈련 - 레이블러가 매긴 순위 사용
- PPO dataset : 사람의 레이블 없음. RLHF fine-tuning의 input

3.3 Tasks

- a dataset of prompts written by our labelers
- a dataset of prompts submitted to early InstructGPT models on our API

이 프롬프트 데이터셋 활용하고, 이 프롬프트는 질의응답, 문장 생성, 요약 등 자연어 처리 작업 내용을 포함함

레이블러들은 프롬프트를 작성한 사용자의 의도를 고려하도록 하고, 불분명한 경우 건너뛰

3.4 Human data collection

40명의 레이블러 고용 - 잠재적으로 위험이 있는 출력을 식별하는 데 능숙한 레이블러를 선별

alignment의 기준에 대해서는 사용자에게 도움이 된다는 점을 우선으로 두고.. 나머지는 향후 연구에게 맡긴다..

일반화 성능을 확인하기 위해 훈련 데이터 작성에 참여하지 않는 레이블러 또한 고용

→ 예상보다 레이블러 그룹 간 차이가 적었다.

3.5 Models

- GPT-3 모델의 사전 훈련 언어 모델 사용 ⇒ 세 가지 다른 기법으로 모델 훈련
 - SFT : 지도 학습으로 파인튜닝. 16 에포크, 0.2 비율의 드롭아웃. RM score 기반으로 최종 모델 선정.
 - RM : 프롬프트-응답 입력으로 받아 스칼라 보상 출력. 175B RM은 불안정할 수 있기 때문에 75B RM 사용. 아래는 RM의 수

$$\text{loss}(\theta) = -\frac{1}{\binom{K}{2}} E_{(x, y_w, y_l) \sim D} [\log(\sigma(r_\theta(x, y_w) - r_\theta(x, y_l)))]$$

- RL : SFT 모델을 PPO 알고리즘 사용하여 파인튜닝 . 무작위 고객 프롬프트 제공 및 응답 기대. 과적합 완화 위해 KL 페널티 추가
 - PPO-ptx : 사전 훈련된 그래디언트를 PPO 그래디언트에 결합한 모델
 - 훈련 중 다음 목적함수 최적화

$$\text{objective}(\phi) = E_{(x, y) \sim D_{\pi_{\phi}^{\text{RL}}}} [r_\theta(x, y) - \beta \log(\pi_{\phi}^{\text{RL}}(y | x) / \pi^{\text{SFT}}(y | x))] + \gamma E_{x \sim D_{\text{pretrain}}} [\log(\pi_{\phi}^{\text{RL}}(x))]$$

- Baseline
 - SFT - GPT3 비교
 - few-shot prefix 유무에 대해 비교

- InstructGPT FLAN&T0 과 비교

3.6 Evaluation

얼마나 aligned 되었는지 평가하기 위함

alignment란 무엇인가? ⇒ helpful, honest and harmless

주어진 프롬프트나 "Q: {question}\nA:" 등 해석이 가능한 패턴에서 의도 파악이 가능해야 함

→ 레이블러의 판단에 의존하지만, 실제 사용자가 아니기 때문에 차이가 생길 수 있다

how to measure honesty : this requires comparing the model's actual output to its "belief"

⇒ 블랙박스, honesty 측정은 어렵기 때문에 truthfulness(사실인가)를 측정

- hallucinations 측정
- TruthfulQA dataset 활용으로 truthfulness 측

measuring the harms of language models : 해로움은 실제 세계에서의 사용에 따라 달라진다.

- 초반 - 잠재적임 해로움 측정(레이블러) 하지만 궁극적으로 어떻게 사용될 지 불분명
- 해로운 행동을 종류별로 측정 - 특정 집단 비하, 폭력적 내용 등...
- RealToxicityPrompts 벤치마크 사용

요약

- API 분포에서 평가 : 보류된 프롬프트 데이터에 대해 평가. (훈련 데이터 제작에 포함되지 않은 레이블러의 데이터 사용)
- 공개된 NLP dataset으로 평가 : 언어 모델의 안정성(truthfulness, toxicity 등)과 여러 태스크에서의 zero-shot 성능 평가 + RealToxicity prompts dataset 활용 평가

04 Results

레이블러 - InstructGPT 출력이 GPT3 출력보다 좋다.




Figure 1: Human evaluations of various models on our API prompt distribution, evaluated by how often outputs from each model were preferred to those from the 175B SFT model. Our InstructGPT models (PPO-ptx) as well as its variant trained without pretraining mix (PPO) significantly outperform the GPT-3 baselines (GPT, GPT prompted); outputs from our 1.3B PPO-ptx model are preferred to those from the 175B GPT-3. Error bars throughout the paper are 95% confidence intervals.

4.1 Results on the API distribution




Figure 3: Preference results of our models, measured by winrate against the 175B SFT model. Left: results on prompts submitted to GPT models on the API; Right: results on prompts submitted to InstructGPT models on the API; Top: results from held-out labelers; Bottom: results from training labelers. We omit GPT (prompted) from the evals on prompts submitted to GPT-3 models (left) as these prompts are already designed to perform well for GPT-3, as opposed to prompts submitted to InstructGPT models (right).

- GPT3 모델에 입력된 프롬프트에서 평가할 때 결과에 큰 차이가 없음




Figure 4: Metadata results on the API distribution. Note that, due to dataset sizes, these results are collapsed across model sizes. See Appendix E.2 for analysis that includes model size. Compared to GPT-3, the PPO models are more appropriate in the context of a customer assistant, are better at following explicit constraints in the instruction and attempting the correct instruction, and less likely to ‘hallucinate’ (meaning, making up information on closed domain tasks like summarization).

- 레이블러(사람)은 InstructGPT에 대해 더 긍정적으로 평가
- 지시했을 때, 이러한 제약을 더 자주 따르고 Hallucination 또한 더 적음
- held-out 레이블러(훈련용 데이터 생성에 참여하지 않은 레이블러)들의 선호도에도 결과 비슷 ⇒ 일반화 성능(과적합X)




Figure 5: Comparing our models with FLAN and T0 in terms of Likert scores on a 1-7 scale, on the InstructGPT prompt distribution. FLAN and T0 perform better than default GPT-3, and comparably with a few-shot GPT-3 model placed into ‘instruction-following’ mode.

- InstructGPT - FLAN, T0에 파인튜닝된 GPT3 비교
 - 더 넓은 분포의 프롬프트 데이터 사용
 - 다양한 입력 수집

- 두 가지의 이유로 InstructGPT의 성능이 더 뛰어남

4.2 Results on public NLP datasets

- TruthfulQA dataset → 이 논문의 PPO 모델이 추가 지시 없이 더 진실성있고 유익한 출력 생성
- 독성에서도 성능이 올랐지만, 편향에서는 개선이 없음
- alignment tax : 공개된 NLP 데이터셋에서 성능 감소
 - PPO-ptx (사전 훈련의 그래디언트 추가-KL coeff 증가시키는 방식) 방식으로 완화 ⇒ 더 보완하기 위한 연구 필요




Figure 6: Results on the TruthfulQA dataset. Gray bars indicate ratings of truthfulness; colored bars indicate ratings of truthfulness *and* informativeness.

4.3 Qualitative results

- 유망한 일반화 능력 - 예시

Prompt:

Écrivez une courte histoire sur une grenouille qui voyage dans le temps jusqu'à la Grèce antique en français.

GPT-3 175B completion:

Écrivez une histoire au sujet d'un enfant qui voudrait tout savoir sur les jeux des dieux et qui se retrouve dans l'une de leurs histoires.

Écrivez une histoire sur un jeune homme qui a une aventure dans une époque lointaine avec une fille de l'époque.

Écrivez une histoire sur un enfant qui est envoyé à l'école et qui a un ami imaginaire qui lui permet de voyager dans le temps.

InstructGPT 175B completion:

La grenouille était perdue et épuisée. Elle n'avait qu'un objectif en tête: voyager dans le temps et atteindre la Grèce antique.

Premier problème, trouver un moyen de transport. Elle avait entendu dire que l'un des meilleurs moyens était de sauter dans une machine temporelle. Elle s'élança, et voilà qu'elle se retrouva dans le passé, au cours d'une nuit étoilée à l'odeur douce et envoûtante.

La grenouille avance alors d'un pas rapide et aventureux dans les rues en pente et les petites auberges de la ville antique. [...]

Prompt:

What is the purpose of the list C in the code below?

```
def binomial_coefficient(n, r):  
    C = [0 for i in range(r + 1)];  
    C[0] = 1;  
    for i in range(1, n + 1):  
        j = min(i, r);  
        while j > 0:  
            C[j] += C[j - 1];  
            j -= 1;  
    return C[r]
```

GPT-3 175B completion:

- A. to store the value of C[0]
- B. to store the value of C[1]
- C. to store the value of C[i]
- D. to store the value of C[i - 1]

InstructGPT 175B completion:

The list C in this code is used to store the values of the binomial coefficient as the function iterates through the values of n and r. It is used to calculate the value of the binomial coefficient for a given value of n and r, and stores the result in the final return value of the function.

- 여전히 실수 가능함(Instruct GPT)
 - 잘못된 전제를 가진 지시
 - 해명형 진술
 - 여러개의 지시 또는 어려운 지

05 Discussion

5.1 Implications for alignment research

- alignment 에 대한 비용이 사전 훈련에 비해 적은 비용이 소모됨

- InstructGPT가 지시 수행을 잘 일반화한다는 증거를 얻어냄
- fine-tuning을 활용하여 성능 저하 완화가 가능
- real World로 alignment 적용 기법 검증

5.2 Who are we aligning to?

- aligning 대상 : 레이블러의 선호도에 따름 (상호 일치율 73%)
- 정렬 주체 : 연구자의 지침을 기반으로 레이블러 정렬 → 연구자의 선호에 영향을 받을 수 있음
- 훈련 데이터의 출처 : OpenAI 실제 고객이 API Playground 에 제출한 프롬프트에 따름
- 고객의 대표성 : 모든 사용자를 대표한다고 보기 어려움
- 정렬 과정의 어려움 : 모든 사람의 선호를 동시에 반영하기 어려움
- 나아갈 방향 : 다양한 그룹을 대표할 수 있는 모델의 학습 방법 찾기

5.3 Limitations

methodology

- 사람의 피드백 - 개인의 믿음, 환경 등에 영향을 받을 수 있음. 또한 레이블러들은 주로 영어를 사용함
- 데이터 수집에 있어서 의견 차이에 대해, 특히 소수 집단에 대해 텍스트를 생성할 때 주의를 기울일 필요가 있음

model

- 완전히 align되거나 안전하지 않다
- 언제든지 실수하고 해를 끼칠 수 있음

5.4 Open questions

- toxicity가 있거나 해로운 출력을 줄이기 위한 방법
- 특정 사용자 지침을 거부

5.5 Broader impacts

- 대형 언어 모델이 특정 인간 집단의 의도에 맞게 작동하도록 훈련함으로써 긍정적인 영향을 늘리려는 목표
- 정렬에 있어서 실패는 심각한 상황을 초래할 수 있음 - 모델과 관련된 안전 문제 해결을 위해 하나의 도구로 사용
 - 특히 신용, 광고, 법 관련 분야에서